Ενδιάμεση Εργασία

Μπαρμπαγιάννος Βασίλειος
ΑΕΜ: 10685
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Περίληψη—Η ενδιάμεση εργασία συγκρίνει την απόδοση των τριών ταξινομητών: 1-**Nearest Neighbour**, 3-**Nearest Neighbours** και **Nearest Centroid**.

I . Εισαγωγή

Η εργασία αφορά τη σύγκριση τριών ταξινομητών όσων αφορά την απόδοση (accuracy). Έχουμε τους ταξινομητές 1-NN, 3-NN και Nearest Centroid.
Οι ταξινομητές NN (Nearest Neighbour) είναι αλγόριθμοι επιβλεπόμενης μάθησης. Προσπαθούν να προβλέψουν τη σωστή κλάση για ένα δείγμα του test set υπολογίζοντας τις αποστάσεις με τους γείτονες, δηλαδή τα δεδομένα του training set.

Ο Nearest Centroid δεν υπολογίζει αποστάσεις από τους γείτονες. Αντιθέτως υπολογίζει για κάθε κλάση το μέσο διάνυσμα χαρακτηριστικών (centroid) των δειγμάτων του training set που ανήκουν σε αυτή. Δηλαδή υπολογίζω 100 centroids. Η ταξινόμηση γίνεται με βάση ποιο centroid είναι πιο κοντά στο test δείγμα.

II . Dataset

Το dataset που χρησιμοποίησα είναι το CIFAR-100 [1]. Αποτελείται από 100 κλάσεις (κατηγορίες), δηλαδή από 100 διαφορετικά είδη εικόνων, μεγέθους 32x32 pixels η κάθε εικόνα. Κάθε κλάση περιέχει 600 εικόνες: 500 εξ αυτών είναι για το training και 100 για το testing. Έχουμε 100 κλάσεις επί 600 εικόνες έκαστη, σύνολο 60.000 εικόνες. Το training set περιέχει 50.000 εικόνες, ενώ το testing set περιέχει 10.000 εικόνες.

Το CIFAR-100 δατασετ είναι οργανωμένο σε πέντε data batches και ένα test batch. Κάθε data batch είναι ένας πίνακας $10.000x3072$. Κάθε γραμμή αυτού του πίνακα είναι μια διαφορετική εικόνα, η οποία περιέχει 3072 pixels (σε flat μορφή).

III . Validation Set

Το CIFAR-100 δεν περιέχει validation set. Περιέχει μόνο training set (50.000 εικόνες, δηλαδή δείγματα) και testing set (10.000 εικόνες). Φτιάχνουμε εμείς validation set από το training set ως εξής:
Από το training set κρατάω 30.000 δείγματα (το 60%) και εδώ εκπαιδεύω το μοντέλο.
Στα υπόλοιπα 20.000 δείγματα (το 40%) ελέγχω/αξιολογώ το μοντέλο. Το testing set μένει ως έχει. Στο testing set ελέγχω/αξιολογώ το μοντέλο σε δεδομένα που δεν έχει δει κατά τη διάρκεια της εκπαίδευσης. Είπαμε στην εισαγωγή ότι οι αλγόριθμοι δεν εκπαιδεύονται. Πράγματι, εδώ χρησιμοποιούμε καταχρηστικά τον όρο ¨εκπαίδευση' για να δηλώσουμε τους υπολογισμούς της απόστασης ενός δείγματος του test set με τα δείγματα του train set που λαμβάνουν χώρα.

IV . Ζητούμενο εργασίας

Έχω να συγκρίνω την απόδοση τριών ταξινομητών:

- 1-NN
- 3-NN
- Nearest Centroid

Αυτοί είναι ταξινομητές βασισμένοι στην εκπαίδευση. Δεν είναι ούτε νευρωνικά, ούτε k-means. Δεν εκπαιδεύονται. Οπότε δεν χρειαζόμαστε validation set.

V . 1-NN και 3-NN

Έχω ένα άγνωστο δείγμα (μια άγνωστη εικόνα 32x32 pixels). Παίρνω τις αποστάσεις αυτού του δείγματος από όλα τα δείγματα που βρίσκονται στο training set. Στη περίπτωση του 1-NN κοιτάω τι ετικέτα (label) έχει ο κοντινότερος γείτονας αυτού του άγνωστου δείγματος, οπότε και το άγνωστο δείγμα έχει το ίδιο label. Στον 3-NN κοιτάω το label. των τριών κοντινότερων γειτόνων και διαλέγω αυτό που εμφανίζεται συχνότερα. Παραδείγματος χάρη, αν οι τρεις κοντινότεροι γείτονες έχουν labels $5, 12, 12$ τότε θα επιλέξω το 12.

VI . Nearest Centroid

Σε αυτό το ταξινομητή υπολογίζω για κάθε κλάση (έχουμε 100 κλάσεις) το μέσο διάνυσμα χαρακτηριστικών (centroid) των δειγμάτων του training set ου ανήκουν σε αυτή. Δηλαδή υπολογίζω 100 centroids, ένα για κάθε κλάση. Την ταξινόμηση την κάνω με βάση ποιο centroid είναι πιο κοντά στο test δείγμα.

VII . Διαστάσεις

Το CIFAR-100 dataset είπαμε ότι περιέχει 60.000 εικόνες. Κάθε μία εικόνα έχει διάσταση 32x32 πιξελς. Όμως είναι και RGB, δηλαδή περιέχει 3 χρώματα. Άρα κάθε εικόνα είναι ένας τρι-διάστατος πίνακας $32x32x3$. Αν κάνω αυτόν τον πίνακα επίπεδο διάνυσμα (flat) τότε θα παίρνω διάνυσμα $3072x1$. Συνεπώς κάθε εικόνα θεωρείται πλέον ένα διάνυσμα αυτής της διάστασης.

VIII . Μείωση διάστασης

Επειδή η κάθε εικόνα, το κάθε δείγμα δηλαδή, έχει μεγάλη διάσταση ($3072x1$) θα ήταν σοφότερο να μειώσουμε τη διάσταση με ανάλυση κυρίων συνιστωσών (Principal Components Analysis - PCA). Δεν θα χάσουμε όμως πληροφορία. Μειώνουμε τη διάσταση σε 100 ή 50, οπότε κάθε δείγμα είναι ένα διάνυσμα $100x1$ ή $50x1$. Με το PCA κρατήσαμε τις διαστάσεις με τη μεγαλύτερη διακύμανση, δηλαδή αυτές που εξηγούν καλύτερα τα δεδομένα και όχι απαραίτητα τις διαστάσεις που βοηθούν περισσότερο στην ταξινόμηση.

Σε προβλήματα ταξινόμησης θέλουμε χαρακτηριστικά που διαχωρίζουν τις κλάσεις. Στις εικόνες, τα pixels που την αποτελούν περιέχουν ποικιλία και ποικιλομορφία χρωμάτων.

IX . Confusion Matrix

Οι τιμές στη διαγώνιο πρέπει να είναι μεγάλες και δηλώνουν σωστή (ορθή) ταξινόμηση. Οι τιμές εκτός διαγωνίου πρέπει να είναι μικρές και δηλώνουν λανθασμένη ταξινόμηση. Άρα αν εκτός της διαγωνίου έχω μεγάλες τιμές, τότε η ταξινόμηση έγινε λάθος. Παραδείγματος χάρη, η ετικέτα στον άξονα x του confusion matrix ταξινομήθηκε λανθασμένα ως ετικέτα του άξονα y.

X . Αποτελέσματα

Πίνακας I
Ακρίβεια ταξινομητών με χρήση PCA

Ταξινομητής	**Accuracy**	**Train Time (s)**	**Predict Time (s)**
1-NN	0.1941	0.02	6.75
3-NN	0.1630	0.01	5.51
Nearest Centroid	0.1003	0.08	0.02

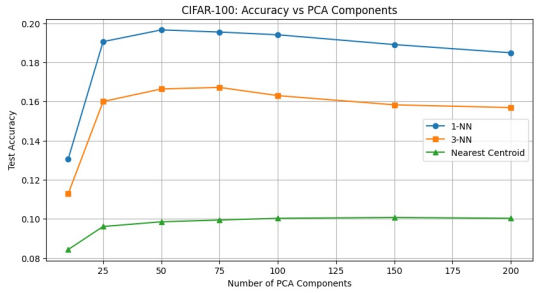

Σχήμα 1. Σχέση μεταξύ ακρίβειας ταξινόμησης και αριθμού PCA components στο CIFAR-100 dataset.

Πίνακας II
Ακρίβεια ταξινομητών χωρίς PCA

Ταξινομητής	**Accuracy**	**Train Time (s)**	**Predict Time (s)**
1-NN	0.1755	0.17	132.08
3-NN	0.1479	0.08	132.64
Nearest Centroid	0.1004	3.35	0.56

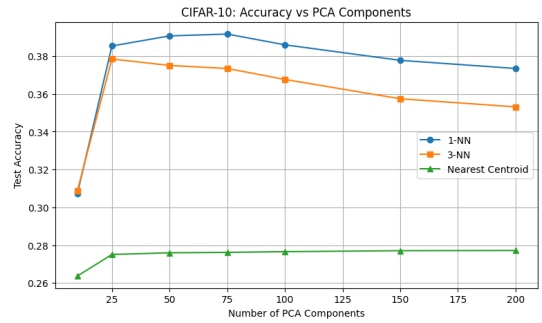

Σχήμα 2. Σχέση μεταξύ ακρίβειας ταξινόμησης και αριθμού PCA components στο CIFAR-10 dataset.

XI . Σχολιασμός αποτελεσμάτων

Παρατηρούμε στον πίνακα 1 ότι την υψηλότερη ακρίβεια την πετυχαίνει ο ταξινομητής 1-NN. Ακολουθεί ο 3-NN και τελευταίος βρίσκεται ο Nearest Centroid. Οι χρόνοι εκπαίδευσης και για τους τρεις ταξινομητές είναι αμελητέος αφού όπως είπαμε δεν ¨εκπαιδεύονται¨, δεν έχουν κάτι να εκπαιδεύσουν, απλώς αποθηκεύουν τα δείγματα. Οι χρόνοι πρόβλεψης για τους ταξινομητές 1-NN και 3-NN είναι φυσιολογικά μεγάλοι αφού πρέπει να υπολογίσουν αποστάσεις από κάθε άλλο δείγμα. Από την άλλη, ο ταξινομητής Nearest Centroid παρουσιάζει ελάχιστα μεγαλύτερο χρόνο εκπαίδευσης αφού χρειάζεται να υπολογίσει τα 'centroids¨. Επίσης παρουσιάζει αμελητέο χρόνο πρόβλεψης αφού για το άγνωστο test δείγμα πρέπει να υπολογιστούν οι αποστάσεις μόνο για τα 100 centroids.

Στο σχήμα 1 βλέπουμε ότι η ακρίβεια της τάξεως 0.1941 για τον 1-NN πετυχαίνεται με 50 PCA συνιστώσες. Ο ταξινομητής 3-NN πετυχαίνει τη μέγιστη ακρίβεια 0.1630 με 75 συνιστώστες. Και τέλος ο Nearest Centroid πετυχαίνει 0.1003 με 200 συνιστώσες.

Εκτελέσαμε το πείραμα και χωρίς την εφαρμογή Principal Components Analysis. Ο πίνακας II παρουσιάζει τα αποτελέσματα για καθένα ταξινομητή. Οι ακρίβειες είναι μικρότερες για τους ταξινομητές NN ενώ για τον Nearest Centroid έμεινε σχεδόν σταθερή. Αξιοσημείωτη είναι η διαφορά στους χρόνους εκπαίδευσης και πρόβλεψης. Σταθερά οι 1-NN και 3-NN έχουν αμελητέο χρόνο εκπαίδευσης (για τον ίδιο λόγο που αναφέραμε προηγουμένως) ενώ ο χρόνος εκπαίδευσης για τον Nearest Centroid αυξήθηκε στα 3.35 seconds. Αυτό συμβαίνει διότι, χωρίς PCA πλέον, τα δείγματα εικόνων αυξήθηκαν!!! Πλέον δεν κρατάμε μόνο 50 ή 100 συνιστώσες. Αλλά έχουμε όλα τα δείγματα, και τα 50.000 για εκπαίδευση.

Ωστόσο, ο Nearest Centroid έχει ελάχιστο χρόνο πρόβλεψης, αφού όπως είπαμε, μετρά τις αποστάσεις μόνο για τα 100 centroids. Εκτίναξη παρατηρείται στους χρόνους πρόβλεψης των 1-NN και 3-NN!!! Αυτό συμβαίνει διότι χρειάζεται, για κάθε άγνωστο δείγμα, να υπολογιστούν οι αποστάσεις από 50.000 γείτονες! Και αυτό είναι προφανώς χρονοβόρο!

Για λόγους σύγκρισης και μόνο προσθέσαμε και την ακρίβεια που πετυχαίνουν οι τρεις ταξινομητές για το cifar-10 dataset. Παρατηρώ ότι η ακρίβεια για τους ταξινομητές είναι αρκετά μεγαλύτερη. Αυτό έχει μια λογική εξήγηση. Το

cifar-10 dataset έχει 10 κλάσεις αντί για 100 και προφανώς οι ταξινομητές δύνανται να ταξινομήσουν το άγνωστο δείγμα ευκολότερα.

XII . Συμπέρασμα

Από την παραπάνω μελέτη συνάγεται το συμπέρασμα ότι η ακρίβεια των ταξινομητών με χρήση Principal Component Analyis είναι μεγαλύτερη (αλλά όχι τρομακτικά μεγαλύτερη) από ότι αν δεν χρησιμοποιούσαμε. Επίσης, οι χρόνοι εκπαίδευσης για τους ταξινομητές 1-NN και 3-NN είναι ασήμαντοι είτε με εφαρμογή PCA είτε χωρίς. Το ίδιο και για τον χρόνο πρόβλεψης του ταξινομητή Nearest Centroid. Ωστόσο, οι ταξινομητές 1-NN και 3-NN γίνονται τρομακτικά χρονοβόροι εάν δεν χρησιμοποιήσουμε τεχνική PCA, ενώ λιγότερο χρονοβόρος γίνεται ο Nearest Centroid χωρίς PCA. Σε κάθε περίπτωση, τη μεγαλύτερη ακρίβεια ταξινόμησης (classification accuracy) την παρουσιάζει ο 1-NN ενώ την μικρότερη ο Nearest Centroid.

Αναφορές

[1] A. Krizhevsky, “Learning Multiple Layers of Features from Tiny Images,” Technical Report, University of Toronto, 2009. (Chapter 3 describes the dataset and collection methodology in detail.)